计量经济学

“约会软件中的阶级符号展示与收入分层：基于 OkCupid Profiles 的实证分析”

或者稍微更有风格一点：

“谁在约会软件上展示阶级符号？基于 OkCupid 用户画像的收入与自我呈现研究”

这份数据一共有 `59,946` 个样本，主要字段包括：

- `age`
- `sex`
- `orientation`
- `education`
- `income`
- `job`
- `location`
- `essay0` 到 `essay9`

几个关键发现：

- `income` 表面上不缺失，但其中 `-1` 基本表示“未报告收入”。
- 真正报告了收入的人只有 `11,504`，大约占 `19.2%`。
- 文本信息很丰富，至少有一栏 essay 的样本占 `96.5%`，非常适合构造“阶级符号指数”。
- 我用一组初始关键词做了非常粗的“阶级符号”计数，结果发现：
  - 报告高收入的人，平均“阶级符号词”更多
  - 在可用样本里，高收入组的平均词数约 `3.85`
  - 非高收入组约 `3.33`
- 按“阶级符号词频”分四组时，高收入占比大致从 `30.2%` 上升到 `40.6%`，说明这个方向至少在描述统计上是有信号的。

这说明两件事：
第一，你们的题目**能做出结果**。
第二，这个结果更像是“收入与阶级符号展示是否相关”，而不是“阶级符号是否提升择偶市场表现”。

研究问题可以定成：

在约会软件中，用户的阶级符号展示是否与其收入水平显著相关？这种关系在性别、性取向和教育群体之间是否存在差异？

对应变量设计：

被解释变量：

- `HighIncome_i`
- 把 `income >= 80000` 定义为高收入，前提是 `income != -1`

核心解释变量：

- `ClassSignal_i`
- 由 `essay0-essay9` 文本构造“阶级符号指数”

控制变量：

- `age`
- `sex`
- `orientation`
- `education`
- `job`
- `location`

基准模型：

```
HighIncome_i = β0 + β1 ClassSignal_i + β2 Age_i + β3 Female_i + β4
Orientation_i + β5 Education_i + β6 Job_i + β7 Location_i + ε_i
```

你们后面可以做两套回归：

- 线性概率模型 `OLS`
- `Logit/Probit` 作为稳健性检验

下一步具体怎么做

1. 清洗样本

- 删除 `income = -1` 的样本
- 删除 `education`、`job` 严重缺失的样本
- 保留 essay 至少有文本的样本

2. 构造收入变量

- 先做一个二元变量：`HighIncome = 1[income >= 80000]`
- 稍后再试不同门槛，比如 `50000` 或 `100000` 做稳健性

3. 构造“阶级符号指数”
   最开始不要一上来做太复杂，先做最简单可解释版本：

- 把 10 个 essay 合并
- 统计高文化资本/高消费/国际流动相关词汇出现次数
- 再标准化成一个指数

建议初版关键词分三类：

- 文化资本：
  `philosophy, literature, museum, gallery, opera, jazz, theater`
- 消费与生活方式：
  `wine, whiskey, cocktail, luxury, brunch`
- 国际流动与教育身份：
  `travel, europe, paris, graduate, academia, intellectual`

4. 做描述统计
   至少出 3 张表/图：

- 样本基本特征表
- 报告收入样本 vs 未报告收入样本对比
- 不同阶级符号强度组的高收入比例图

5. 跑基准回归

- 先只放 `ClassSignal + age + sex + orientation`
- 再加入 `education/job/location`
- 看 `β1` 是否稳定

6. 做异质性分析
   优先做这三个：

- 男 / 女
- 异性恋 / 非异性恋
- 高教育 / 低教育

7. 做稳健性检验

- 换高收入阈值
- 换阶级符号指数构造方式
- 去掉极端词频用户

8. 写局限性
   这一点一定要提前准备：

- 收入是自报数据，可能误报
- 大量用户未报告收入，存在选择性偏差
- 阶级符号是文本构造变量，有测量误差
- 数据是横截面，不能强做因果解释

模拟第一次组会

- 题目有意思
- 数据已经拿到
- 变量能落地
- 回归可以做
- 风险你们也想到了

第一部分：一句话讲题目

“我们想研究的是：
· 在约会软件里，用户会不会通过文本自我介绍展示某种阶级符号，比如文化品味、消费方式和教育身份；
· 这种展示是否和收入分层存在显著关系。”

第二部分：为什么这个题目值得做

“这个题目把数字平台、自我呈现和社会分层联系起来了。传统收入分层研究多看教育、职业和家庭背景，但在平台环境下，人们还会主动经营形象。我们想看这种形象建构和经济地位之间有没有系统关系。”

第三部分：数据是什么

“我们使用 Kaggle 上的 OkCupid Profiles 数据，共约 6 万个用户样本，包含年龄、性别、性取向、教育、职业、收入以及 10 栏自我介绍文本。其中文本信息很丰富，适合构造‘阶级符号展示’变量。”

第四部分：目前的数据发现

“我们已经完成了初步摸底。总样本约 5.99 万，但真正报告收入的样本约 1.15 万，占 19.2%。essay 文本覆盖率很高，约 96.5%。我们用一组初始关键词构造了一个很粗的阶级符号指标，发现高收入样本的相关词频平均值更高，而且随着阶级符号强度上升，高收入占比也在上升，所以这个方向是有初步信号的。”

第五部分：准备怎么做实证

“基准回归会把高收入作为被解释变量，把文本中的阶级符号指数作为核心解释变量，并控制年龄、性别、性取向、教育和职业。后续会做异质性分析和稳健性检验，比如不同收入门槛、不同关键词表和不同群体分组。”

第六部分：局限性

“这个题目的主要限制是收入是自报的，而且未报告比例较高，所以我们会把研究定位为平台自我呈现与收入分层的相关性分析，而不是严格的因果识别。”

组会上可以直接念的简版口头稿

“我们组选题聚焦约会软件上的自我呈现和收入分层。我们用的是 OkCupid Profiles 数据，样本接近 6 万，包含年龄、性别、性取向、教育、职业、收入和多栏自我介绍文本。我们的核心想法是把用户文本里的文化资本、消费方式和教育身份表达量化成一个‘阶级符号指数’，然后检验它和收入水平之间的关系。目前我们已经完成了数据摸底，发现虽然只有约 19% 的用户报告了收入，但仍有 1.1 万左右的可用样本，而且文本覆盖率很高。初步统计显示，阶级符号更强的用户，高收入占比更高。下一步我们会完成变量构造、基准回归、异质性分析和稳健性检验，并把研究定位为平台中的自我呈现与社会分层研究。”

你们第一次组会最好形成的分工
建议你当场就推进成这样：

- 1 人负责文献综述
  关键词：online dating, self-presentation, status signaling, cultural capital, class identity
- 1 人负责数据清洗和变量构造
  重点：income、education、job、essay 合并与文本指数
- 1 人负责回归与 PPT 框架
  重点：描述统计表、模型式、结果展示模板

我建议你接下来立刻做的事
下一步最值得做的是：我直接帮你把“阶级符号指数”的第一版词表和清洗方案定下来，并给你一份可以直接照着写的 Stata / Python 分析流程。

如果你愿意，我下一条就可以继续给你这三样东西：

1. 第一版“阶级符号指数”词表
2. 变量表怎么写
3. 从清洗到回归的完整步骤清单